

De données "brutes" à l'information consolidée avec Wikidata

Collecter · Réconcilier · Structurer · Publier

Un pipeline GLAM complet pour valoriser vos connaissances érudites en Linked Open Data, Schema.org et HTML sémantique.



Plan de l'atelier

01

Collecte collaborative

Un GSheet partagé → CSV éditable publié en ligne.
Chaque participant ajoute lieux, personnes, faits.

02

Réconciliation Wikidata

OpenRefine charge le CSV, désambiguïse les entités
et les lie aux Q-identifiants Wikidata.

03

Schema.org & microddat ou JSON-LD

On choisit un type Schema.org adapté (Place, Person...)
et on valide avec l'outil Google + OSDS.

04

Page HTML publiée

Une collection de faits enrichie en Linked Data, ccessible et indexable par les moteurs et les IA.

Collecte Collaborative avec Google Sheets

Structure du tableur partagé

Colonne	type	nom	description	date	lieu	source_url	wikidata_qid
Exemple	Person	Ibn Battuta	Explorateur...	1304	Tanger	bnrm.ma/...	Q296252
	Place	BNRM	Bibliothèque...	1996	Rabat	bnrm.ma	À compléter

Protocole de saisie

- Une ligne = une entité (lieu, personne, fait, œuvre)
- Remplir au minimum : type, nom, description, source_url
- Laisser wikidata_qid vide → sera complété via OpenRefine
- Publier en CSV : Fichier → Partager → Publier (format CSV)



Astuce CSV public

L'URL du CSV suit le pattern :
docs.google.com/.../pub?output=csv

Réconciliation avec OpenRefine & Wikidata

Importer le CSV

- 1 Ouvrir OpenRefine → Créer un projet → coller l'URL du CSV Google Sheets publié → Créer le projet.

Réconcilier une colonne

- 2 Clic sur ▼ colonne "nom" → Réconcilier → Démarrer la réconciliation → Choisir "Wikidata (fr)" → Mapper le type (Person, Place...).

Désambiguïser

- 3 Pour chaque cellule ambiguë : cliquer sur le badge rouge → choisir la bonne entité Wikidata → Valider ou Créer un nouvel élément.

Extraire le Q-identifiant

4

Enrichir via Wikidata

5

Éditer colonne → Ajouter des colonnes depuis Wikidata

Choisir un schéma et structurer en JSON-LD

schema:Person

Exemple : Ibn Battuta

name · birthDate
birthPlace · sameAs
(ISNI)

schema:Place

Exemple : BNRM Rabat

name · description
geo · url · containedIn

schema:ScholarlyArticle

Exemple :

Publication GLAM

headline · author
datePublished · publisher

Exemple JSON-LD généré (extrait)

```
<script type="application/ld+json">
{
  "@context": "https://schema.org",
  "@type": "Person",
  "name": "Ibn Battuta",
  "birthDate": "1304",
  "birthPlace": { "@type": "Place", "name": "Tanger" },
  "sameAs": "https://www.wikidata.org/wiki/Q296252"
}
</script>
```

Outils de validation

- ✓ Google Rich Results Test
- ✓ OSDS (schema.org validator)
- ✓ schema.org/docs/full.html
- ✓ JSON-LD Playground

Publication d'une collection HTML sémantique

Anatomie de la page HTML

<head>	Balises meta + JSON-LD (données structurées)
<header>	Titre de la collection, description, ORCID auteur
<main>	Liste d'articles <article itemscope>...</article>
<article>	Entité avec itemtype Schema.org + sameAs Wikidata
<footer>	Licence, date de mise à jour, liens BNRM

Flux de travail assisté par IA

- 1. Générer avec l'IA**
Demander à Claude de convertir
les données CSV en blocs HTML+JSON-LD
- 2. Valider le formalisme**
Valider sur schema.org
Ou Google Rich Results Test
- 3. Vérifier l'exactitude**
Comparer chaque sameAs avec
la fiche Wikidata correspondante
- 4. Publier**
GitHub Pages, Netlify ou
serveur institutionnel BNRM et tester avec OSDS

Utiliser l'IA sans lui faire aveuglément confiance



Ce que l'IA fait bien

Génère le JSON-LD à partir d'un tableau de données

Propose des types Schema.org adaptés au contexte

Rédige les descriptions en plusieurs langues

Transforme CSV → HTML sémantique en masse

Suggère **des** propriétés Wikidata pertinentes (P-codes)



Ce que VOUS validez

OSDS : formalisme Schema.org correct ?

Google Rich Results : rendu enrichi prévu ?

Wikidata : le Q-identifiant existe-t-il vraiment ?

ORCID : l'auteur est-il bien disambigué ?

Lien sameAs : URL permanente et résolvable ?

Checklist & Ressources

- ☒ Créer / vérifier votre ORCID
- ☐ Remplir le GSheet partagé (≥ 3 entités)
- ☐ Importer le CSV dans OpenRefine
- ☐ Réconcilier la colonne 'nom' avec Wikidata
- ☐ Extraire les Q-identifiants (wikidata_qid) et augmenter les informations
- ☐ Choisir le bon type Schema.org
- ☐ Générer le JSON-LD (avec l'IA)
- ☐ Valider via schema validator + Google Rich Results
- ☐ Publier la page HTML + tester OSDS

Ressources clés

Identité

- orcid.org
- isni.org

Données

- wikidata.org
- query.wikidata.org (SPARQL)
- dbpedia.org

Structure

- schema.org + microdonnées
- ou JSON-LD
- validator.schema.org + OSDS

Outils

- openrefine.org
- github.com/pages
- tableur en ligne

Notre pipeline d'informations sémantisées publiées et documentées

①

Collecter

Structurer des entités dans
un tableur collaboratif publié
en CSV

②

Réconcilier

Désambiguïser et ancrer dans Wikidata
via OpenRefine

③

Décrire

Choisir un vocabulaire
Schema.org et l'encoder en
JSON-LD

④

Valider

OSDS + Google Rich Results :
formalisme et exactitude

⑤

Publier

Page HTML sémantique
indexable par moteurs et IA

→ 05 mai
SIEL

LOD · RAG
Médiation 3.0